

คำถาม 1

ระบุปัญหาที่พบอย่างน้อย 5 ปัญหา และจับคู่กับมิติ Data Quality อย่างน้อย 3 มิติ

ปัญหาที่พบ	คอลัมน์ที่พบ	มิติ Data Quality	หลักฐาน / จำนวนแถว
1. ค่าสูญหาย (Missing Values)	Customer_Email	Completeness (ความครบถ้วน)	พบช่องว่าง / ค่า Null/NaN ในคอลัมน์อีเมลของลูกค้า
2. รูปแบบวันที่ไม่เป็นมาตรฐานเดียวกัน	Transaction_Date	Consistency (ความสอดคล้อง)	พบการผสมกันระหว่างรูปแบบ DD/MM/YYYY, MM/DD/YYYY และ YYYY-MM-DD ในชุดข้อมูลเดียวกัน
3. ยอดขายไม่ตรงกับสูตรคำนวณพื้นฐาน	Transaction_Amount	Accuracy (ความถูกต้อง)	ยอดรวมไม่เท่ากับ (Unit_Price * Quantity) - Discount ในรายการที่ไม่ได้ระบุโปรโมชั่น
4. รูปแบบอีเมลไม่ถูกต้องตามโครงสร้าง	Customer_Email	Validity (ความสมเหตุสมผลตามรูปแบบ)	พบรายการที่ขาดเครื่องหมาย @ หรือไม่มี Domain Name เช่น user.gmail.com หรือ john.doe@
5. รายการธุรกรรมซ้ำซ้อน	Transaction_ID	Uniqueness (ความไม่ซ้ำซ้อน)	พบ Transaction_ID เดียวกันปรากฏมากกว่า 1 แถว โดยมีรายละเอียดสินค้าและยอดเงินเหมือนกันทุกประการ

คำถาม 2

อธิบายว่าเหตุใดการใช้ 'dropna()' กับ 'Customer_Email' อาจทำให้ยอดขายรวมใน Data Warehouse ผิดเพี้ยน และเหตุใดการเติมค่าเฉลี่ยจึงไม่เหมาะสมกับข้อมูลประเภทอีเมล

ตอบ

- เหตุผลที่ไม่ควรใช้ dropna() กับ Customer_Email เพราะ การสั่งลบแถว (dropna()) โดยที่รู้ว่าไม่มีข้อมูลอีเมล จะทำให้รายการธุรกรรม (Transaction Record) ในแถวนั้นถูกลบทิ้งไปด้วย ซึ่งในรายการนั้นมีการซื้อขายและเกิดรายได้จริง ถ้าลบออกไปจะส่งผลให้ ยอดขายรวม (Total Sales) ใน Fact Table ของ Data Warehouse ต่ำกว่าความเป็นจริง และทำให้รายงานทางการเงินผิดเพี้ยน

และ

- เหตุผลที่ไม่ควรเติมค่าเฉลี่ย เพราะ ข้อมูลประเภทอีเมลเป็น Categorical Data (ข้อมูลเชิงคุณภาพ/ข้อความ) ไม่ใช่ข้อมูลเชิงตัวเลข (Numerical Data) จึงไม่สามารถนำมาคำนวณทางสถิติเพื่อหาค่าเฉลี่ยได้ และ แก้โดยการเติมค่าด้วยข้อความระบุสถานะ เช่น 'Unknown' หรือ 'N/A' เพื่อรักษาแถวรายการธุรกรรมเอาไว้

คำถาม 3

ยกตัวอย่าง 1 วันที่สามารถตีความได้ทั้ง DD/MM/YYYY และ MM/DD/YYYY แล้วอธิบายว่าคุณใช้หลักฐานใดช่วยตัดสิน

ตอบ 05/04/2024 (ตีความได้เป็น วันที่ 5 เมษายน 2024 หรือ วันที่ 4 พฤษภาคม 2024)

หลักฐานที่ใช้ช่วยตัดสินใจคือ การตรวจหาจุดอ้างอิงในคอลัมน์ โดยจะตรวจสอบแถวอื่นๆ ในคอลัมน์เดียวกัน หากพบตัวเลขที่เกิน 12 ในตำแหน่งแรก เช่น 25/04/2024 จะสรุปได้ทันทีว่ารูปแบบของชุดข้อมูลนี้คือ DD/MM/YYYY และ ลำดับเวลาของธุรกรรม โดยจะเปรียบเทียบกับ Transaction_ID หรือเวลาในการบันทึกข้อมูลของรายการก่อนหน้าและถัดไป หากรายการก่อนหน้าคือ 04/04/2024 และรายการถัดไปคือ 06/04/2024 วันที่ 05/04/2024 จะต้องหมายถึงวันที่ 5 เมษายน แน่นนอน

คำถาม 4

รายการที่ 'Transaction_Amount' ไม่ตรงกับสูตรควรแก้ไขทุกแถวหรือไม่? ให้อธิบายผลของ 'Is_Promotion' ต่อการตัดสินใจ

ตอบ ไม่ควรแก้ไขทุกแถวทันที เพราะ ถ้า Is_Promotion = True หากรายการนั้นอยู่ในช่วงโปรโมชั่น การที่ Transaction_Amount ต่ำกว่าผลคูณปกติ อาจเกิดจาก ส่วนลดพิเศษ ของแถม หรือคูปอง ซึ่งถือเป็นยอดขายสุทธิที่เกิดขึ้นจริงทางธุรกิจ (Business Reality) ห้ามแก้ไขค่าให้เท่ากับราคาเต็ม

และ ถ้า Is_Promotion = False หากไม่มีโปรโมชั่นแต่ยอดเงินไม่ตรงกับสูตรคำนวณ แสดงว่าเป็นข้อผิดพลาดจากการบันทึกข้อมูล ในกรณีนี้จึงค่อยทำการคำนวณปรับแต่งค่าใหม่ให้ถูกต้อง

คำถาม 5

เพราะเหตุใดข้อมูลที่อยู่นอก IQR Bound จึงไม่จำเป็นต้องเป็นข้อมูลผิดเสมอ? ยกตัวอย่างจาก Dataset นี้

ตอบ เพราะข้อมูลที่หลุดช่วง IQR หรือค่าทางสถิติที่ดูเป็น Outlier ไม่ได้แปลว่าเป็นข้อมูลที่ "ผิดพลาด" เสมอไป แต่มักเป็น Natural Outlier ซึ่งเป็นพฤติกรรมจริงในทางธุรกิจที่เกิดขึ้นไม่บ่อยบ่อย

เช่น รายการสั่งซื้อที่มี Quantity หรือ Transaction_Amount สูงกว่าปกติมากๆ ในแถวที่มี Is_Promotion = True หรือเป็นช่วงแคมเปญใหญ่ (เช่น Flash Sale, 11.11) หรือเป็นกลุ่มลูกค้ารายใหญ่ (B2B/Wholesale) ยอดขายที่พุ่งสูงนี้เป็นธุรกรรมจริง ไม่ใช่ข้อมูลขยะ ถ้าลบทิ้งเพียงเพราะเป็น Outlier จะทำให้รายงานยอดขายและวิเคราะห์พฤติกรรมลูกค้าบิดเบือนไปจากความเป็นจริง